

DOCUMENTATIE PROIECT STATISTICA

Alexandrescu Mihaela-Isabelle

Balaban Teodor

Poenaru Gabriela-Catalina

February 3, 2021

1 Exercițiul 1

1. Generați 100 000 de valori dintr-o variabilă aleatoare folosind **metoda transformării inverse** pentru repartițiile definite mai jos:

a) *Repartiția logistică* are densitatea de probabilitate $f(x) = \frac{1}{\beta} \frac{e^{-(x-\mu)/\beta}}{(1 + e^{-(x-\mu)/\beta})^2}$ și funcția de

$$\text{repartiție } F(x) = \frac{1}{1 + e^{-(x-\mu)/\beta}}.$$

b) *Repartiția Cauchy* are densitatea de probabilitate $f(x) = \frac{1}{\pi\sigma} \frac{1}{1 + \left(\frac{x-\mu}{\sigma}\right)^2}$ și funcția de

$$\text{repartiție } F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{x-\mu}{\sigma}\right).$$

Comparați rezultatele obținute cu valorile date de funcțiile **rlogis** și respectiv **rcauchy** (funcțiile de repartiție predefinite în **R** pentru repartițiile logistică și respectiv Cauchy). Ilustrați grafic aceste rezultate.

a) Funcția de repartiție este continuă. Putem calcula inversa, astfel:

$$\begin{aligned} F(x) &= u \\ \frac{1}{1 + e^{\frac{-(x-\mu)}{\beta}}} &= u \Rightarrow (1 + e^{\frac{-(x-\mu)}{\beta}}) = \frac{1}{u} \\ u(1 + e^{\frac{-(x-\mu)}{\beta}}) &= 1 \\ 1 + e^{\frac{-(x-\mu)}{\beta}} &= \frac{1}{u} \\ e^{\frac{-(x-\mu)}{\beta}} &= \frac{1}{u} - 1 \Rightarrow \ln\left(\frac{1}{u} - 1\right) = \frac{-(x-\mu)}{\beta} \\ \frac{-(x-\mu)}{\beta} &= \ln\left(\frac{1}{u} - 1\right) \\ x - \mu &= -\beta \ln\left(\frac{1}{u} - 1\right) \\ x &= -\beta(\ln(1-u) - \ln(u)) + \mu \\ x &= -\beta \ln(1-u) + \beta \ln(u) + \mu \\ F^{-1}(u) &= -\beta \ln(1-u) + \beta \ln(u) + \mu \end{aligned} \tag{1}$$

Rezolvarea exercitiului in R:

Am luat $n=100000$ (nr de valori dintr-o v.a.). Am creat o functie (valori repLogistica) care are ca date de intrare n (nr de observatii), μ si β si care returneaza inversa functiei de repartitie prin metoda transformarii inverse. Apoi am realizat histograma data de observatiile generate cu metoda transformarii inverse si histograma data de observatiile generate cu functia predefinita rlogis.

```
n <- 100000


valori_repLogistica <- function(n, miu, beta)
{
  U <- runif(n) #generam 100000 de observatii dintr-o uniforma
  return (miu-1/beta*log(1-U)+1/beta*log(U)) #returnam inversa functiei de repartitie
}
miu <- 0
beta <- 1
var_1L<-valori_repLogistica(n, miu, beta) #generarea cu ajutorul functiei create de noi
var_2L<-rlogis(n) #generarea cu ajutorul functiei prestabilite rlogis

par(mfrow=c(1,2)) #impartim spatiul de plotare in 2


hist(var_1L,main="Observatii generate cu metoda transformarii inverse",xlab="Valoarea obtinuta",
      ylab="Frecventa",xlim=c(-9, 9),col="magenta",cex.main=0.7)

hist(var_2L,main="Observatii generate cu rlogis",xlab="Valoarea obtinuta",
      ylab="Frecventa",xlim=c(-9, 9),col="yellow",cex.main=0.9)
```

Observatii generate cu metoda transformarii inverse



Observatii generate cu rlogis



Observam ca cele doua histograme sunt aproape identice, deci calculele noastre sunt corecte.

b) Procedam (analog) ca la a) si obtinem:

$$\begin{aligned}
 F(x) &= u \\
 \frac{1}{2} + \frac{1}{\pi} \arctg\left(\frac{x - \mu}{\sigma}\right) &= u \\
 \frac{1}{\pi} \arctg\left(\frac{x - \mu}{\sigma}\right) &= u - \frac{1}{2} \\
 \frac{x - \mu}{\sigma} &= \operatorname{tg}\left(\pi\left(u - \frac{1}{2}\right)\right) \\
 x - \mu &= \sigma \cdot \operatorname{tg}\left(\pi\left(u - \frac{1}{2}\right)\right) \\
 x &= \sigma \cdot \operatorname{tg}\left(\pi\left(u - \frac{1}{2}\right)\right) + \mu \\
 x &= \sigma \cdot \operatorname{tg}\left(\pi\left(\frac{2\pi - 1}{2}\right)\right) + \mu \\
 F^{-1}(u) &= \sigma \cdot \operatorname{tg}\left(\pi\left(\frac{2\pi - 1}{2}\right)\right) + \mu
 \end{aligned} \tag{2}$$

Rezolvarea exercitiului in R:

La b) procedam analog pentru functia de repartitie Cauchy.

```

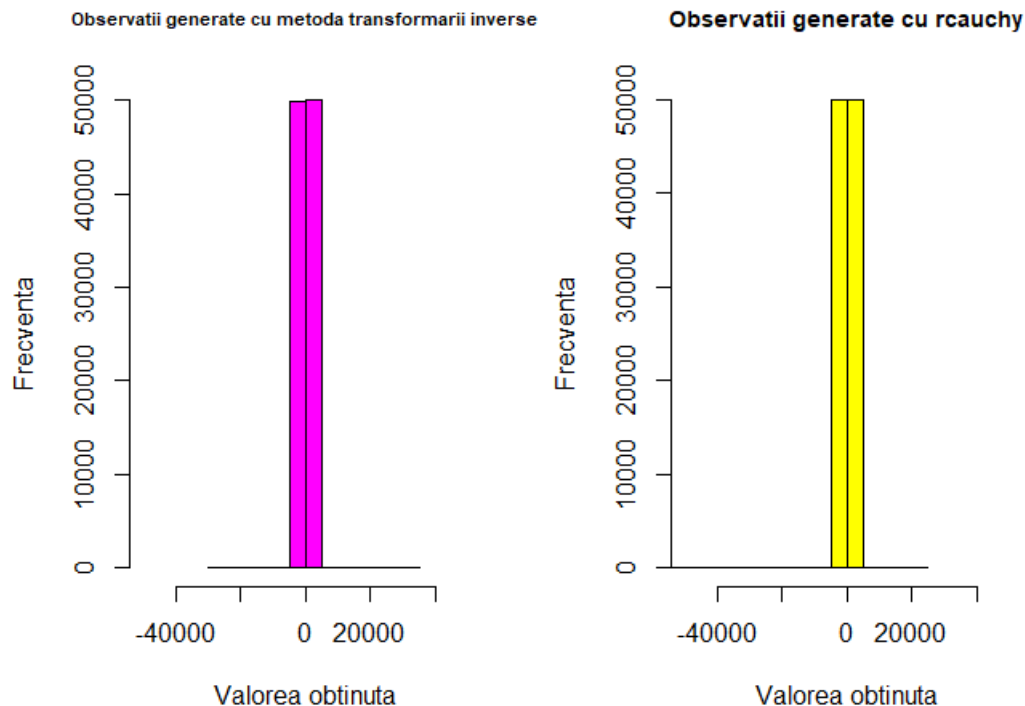
valori_repCauchy <- function(n, miu, sigma){
  U <- runif(n) #generam 100000 de observatii dintr-o uniforma
  return (miu+sigma*tan(pi*(U-1/2))) #returnam inversa functiei de repartitie
}
miu <- 0
sigma <- 1
var_1C <- valori_repCauchy (n,miu,sigma) #observatii generate cu metoda transformarii inverse
var_2C <- rcauchy(n,0,1) #observatii generate cu ajutorul functiei prestabilite rcauchy

par(mfrow=c(1,2)) #impartim spatiul de plotare in 2

hist(var_1C,main="Observatii generate cu metoda transformarii inverse", xlab="Valorea obtinuta",
      ylab="Frecventa", xlim=c(-50000,50000) ,col='magenta',cex.main=0.7)

hist(var_2C,main="Observatii generate cu rcauchy", xlab="Valorea obtinuta",
      ylab="Frecventa", xlim=c(-50000,50000),col='yellow',cex.main=0.9)

```



2 Exercițiul 2

2. Folosiți **metoda respingerii** pentru a genera observații din densitatea de probabilitate definită prin $f(x) \propto \exp(-(x-2)^2 / 8)(\sin(2x)^2 - 2 \cos(x)^2 \sin(3x)^2 + 5)$ parcurgând pașii următori:

(OBS: Notația “ \propto ” înseamnă că $f(x)$ este proporțional cu expresia din dreapta)

- Reprezentați grafic $f(x)$ și arătați că aceasta este mărginită de $Mg(x)$ unde $g(x)$ este densitatea de probabilitate a repartiției normale de medie 2 și dispersie 4. Determinați o valoare potrivită pentru constanta M , chiar dacă nu este optimă.

(Indiciu: Folosiți funcția *optimise* din **R**)

- Generați 100000 de observații din densitatea de mai sus folosind metoda respingerii.
- Deduceți, pornind de la rata de acceptare a acestui algoritm, o aproximare a constantei de normalizare a lui $f(x)$, apoi comparați histograma valorilor generate cu reprezentarea grafică a lui $f(x)$ normalizată.

a) Stim ca $f(x)$ este proportionala cu $h(x)$, deci $f(x)=c \cdot h(x)$. Presupunem

ca $c=1$, deci $f(x)=h(x)$. Adica graficele coincid.

```
#stim ca functia f este proportionala cu h(asadar, f=c*h)
#luam c=1
#definim functia f
f <- function(x){
  return (exp(-(x-2)^2/8)*((sin(2*x))^2-2*(cos(x))^2*(sin(3*x))^2+5))
}
```

Densitatea de probabilitate a normalei este:

$$g(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{\frac{-(x-\mu)^2}{2\sigma^2}} \quad (3)$$

Cum media=2 si dispersia=4 ($\sigma = 2$), avem:

$$g(x) = \frac{1}{2\sqrt{2\pi}} \cdot e^{\frac{-(x-2)^2}{8}} \quad (4)$$

Pentru metoda respingerii ne uitam la raportul $\frac{h}{g}$ i.e. $2\sqrt{2\pi} \cdot (\sin^2(2x) - 2\cos^2(x) \cdot \sin^2(3x) + 5)$. Apoi cu functia optimise aflam M (valoarea maxima a acestui raport).

```
par(mfrow=c(1,2))
v <- seq(-5,10, 0.01) #discretizam intervalul -5,10 pentru a plota
plot(v, f(v), type="l", col = "magenta") #trasam graficul functiei f


#ne uitam la densitatea normalei de medie 2 si dispersie 4 notata cu g
#g=(exp(-(x-2)^2/8))/(2*sqrt(2*pi))

#definesc raportul f/g ca ulterior sa il maximizam pt a gasi constanta M
raport <- function(x)
{
  return ( 2*sqrt(2*pi) *((sin(2*x))^2-2*(cos(x))^2*(sin(3*x))^2+5))
}

#aflu valoarea maxima a acestui raport
M <- optimise(raport, c(0,2), maximum = TRUE)
|

v <- seq(-5,10, 0.01) #discretizam intervalul -5,10 pentru a plota
plot(v, f(v), type="l", col = "magenta") #trasam graficul functiei f
lines(v, dnorm(v,2,2)*M[[2]], col = "black") #suprapunem graficul g*M
```

Trasam in acelasi grafic atat f , cat si $g \cdot M$ si putem observa ca normala margineste functia f .




b) Pentru b) aplicam metoda respingerii.

```
#generam 100000 observatii cu metoda respingerii
n <- 100000 #numar observatii
val_obtinuta <- c() #definim un vector gol in care stocam valorile gasite
k <- 0 #numar observatii valide
for(i in 1:n)
{
  u <- runif(1) #generam o observatie din uniforma
  x <- rnorm(1,2,2) #generam o observatie din normala de medie 2 si dispersie 4
  if( u <= h(x)/(M[[2]]*dnorm(x,2,2)) ) #conditia din algoritmul metodei respingerii
  {
    k <- k + 1 #contorizam numarul observatiilor valide pentru a calcula constanta c
    val_obtinuta[k] <- x #punem in vector valoarea x
  }
}
```

c) Pentru c) contorizam "pasii de acceptare" ai algoritmului pentru ca stim din seminar ca acestia formeaza o variabila aleatoare repartizata geometric, de medie c.

Astfel, reusim sa obtinem constanta c (ea fiind media unei repartitii geometrice).

Realizam histograma valorilor generate, peste care trasam graficul functiei $f(x)$ normalizate.



3 Exercițiul 3

3. Metoda Monte Carlo pentru aproximarea unor integrale

Punctul de plecare al metodei Monte Carlo pentru aproximarea unei integrale este nevoia de a evalua expresia $E_f(h(X)) = \int_X h(x)f(x)dx$, unde X reprezintă mulțimea de valori a variabile aleatoare X (care este, de obicei, suportul densității f).

Principiul metodei Monte Carlo este de a aproxima expresia de mai sus cu media de selecție $\bar{h}_n = \frac{1}{n} \sum_{j=1}^n h(x_j)$ pornind de la un eșantion (X_1, X_2, \dots, X_n) din densitatea f , întrucât aceasta converge a.s. către $E_f(h(X))$, conform legii numerelor mari. Mai mult, atunci când $h^2(X)$ are medie finită viteza de convergență a lui \bar{h}_n poate fi determinată întrucât convergența este de ordin $O(\sqrt{n})$ iar varianța aproximării este $\text{var}(\bar{h}_n) = \frac{1}{n} \int_X (h(x) - E_f(h(X)))^2 f(x)dx$, cantitate care poate fi de asemenea aproximată prin $v_n = \frac{1}{n^2} \sum_{j=1}^n (h(x_j) - \bar{h}_n)^2$.

Mai precis, datorită teoremei limită centrală, pentru un n suficient de mare expresia

$\frac{\bar{h}_n - E_f(h(X))}{\sqrt{v_n}}$ poate fi aproximată cu o normală standard, ceea ce conduce la posibilitatea construirii unui test de convergență și a unor margini pentru aproximarea lui $E_f(h(X))$.

Cerință:

Pentru funcția $h(x) = (1 - x^2)^{\frac{3}{2}}$ construiți o aproximare a integralei acesteia pe intervalul $[0,1]$ după cum urmează:

Valoarea integralei poate fi văzută ca fiind media funcției $h(X)$ unde X este repartizată uniform pe $[0,1]$. Urmărind algoritmul dat de metoda Monte Carlo construiți programul **R** care determină aproximarea acestei integrale. Comparați rezultatul obținut cu cel analitic. Atașați reprezentările grafice pe care le considerați utile pentru a putea observa eficiența metodei.

```

n = 1000 #nr observatiilor

#functia h, a carei integrala vrem sa o aproximam
h = function(x) {
  return ( (1-x^2)^(3/2) )
}

s = 0 #initializam suma pt aproximarea integralei
int = c()

for( i in 1:n) {
  x = runif(1,0,1) #generam cate o observatie din uniforma
  s = s + h(x)
  int[i] = s/i #aici calculam integrala la fiecare iteratie(pentru fiecare observatie)
}
MonteCarlo = s/n #aproximarea finala a integralei


plot(int, type = "l", col = "magenta", xlab = " Pasul ", ylab = "Aproximarea integralei")
abline(h=0.589, col='blue') #valoarea integralei calculata de mana

```

Calculam integrala:

$$\begin{aligned}
 I &= \int_0^1 (1-x^2)^{\frac{3}{2}} dx \\
 \text{Facem S.V. } x &= \sin(y) \\
 I &= \int_0^{\frac{\pi}{2}} \cos(y)^4 dy \\
 &= \int_0^{\frac{\pi}{2}} \frac{1 + \cos(2y)}{2} \cdot \frac{1 + \cos(2y)}{2} dy \\
 &= \frac{1}{4} \int_0^{\frac{\pi}{2}} (1 + 2\cos(2y) + \cos(2y)^2) dy \\
 &= \frac{1}{4} \int_0^{\frac{\pi}{2}} (1 + 2\cos(2y) + \frac{1 + \cos(4y)}{2}) dy \\
 &= \frac{1}{4} \left(y + \sin(2y) + \frac{1}{2}y + \frac{1}{8}\sin(4y) \right) \Big|_0^{\frac{\pi}{2}} \\
 &= \frac{1}{4} \cdot \frac{3\pi}{4} \\
 &= \frac{3\pi}{16} \\
 &\approx 0.589
 \end{aligned} \tag{5}$$

Se observa din grafic ca aproximarea este din ce in ce mai fina cu cat creste numarul de iteratii.



4 Exercițiul 4

4. Construiți două funcții în **R** *frcpois* și respectiv *frcexp* care să calculeze **marginea inferioară Rao-Cramer (MIRC)** pentru varianța estimatorilor parametrilor repartițiilor *Poisson* și respectiv *Exponențială* pentru un eșantion de dimensiune n (generați voi un asemenea eșantion într-o manieră corespunzătoare și folosiți-l în apelul funcției!).

- Funcția *frcpois*:

Funcția de masă a repartiției Poisson este $f_{\lambda}(x) = \frac{\lambda^x \cdot e^{-\lambda}}{x!}$

Aplicăm logaritm natural:

$$\begin{aligned}
\ln(f_\lambda(x)) &= \ln\left(\frac{\lambda^x}{e^\lambda \cdot x!}\right) = \\
&= x \cdot \ln(\lambda) - \lambda \cdot \ln(e) - \ln(x!) = \\
&= x \cdot \ln(\lambda) - \lambda - \ln(x!)
\end{aligned} \tag{6}$$

Derivam in functie de λ de doua ori:

$$\begin{aligned}
\frac{\partial}{\partial \lambda} \ln(f_\lambda(x)) &= \frac{x}{\lambda} - 1 \\
\frac{\partial^2}{\partial \lambda^2} \ln(f_\lambda(x)) &= -\frac{x}{\lambda^2}
\end{aligned} \tag{7}$$

$$\begin{aligned}
E\left[\frac{\partial^2}{\partial \lambda^2} \ln(f_\lambda(x))\right] &= E\left[-\frac{x}{\lambda^2}\right] = \\
&= -\frac{1}{\lambda^2} \cdot E[x] \\
&= -\frac{1}{\lambda^2} \cdot \lambda \\
&= -\frac{1}{\lambda}
\end{aligned} \tag{8}$$

In calculele de mai sus ne-am folosit de faptul ca $E[c \cdot x] = c \cdot E[x]$ si $E[x] = \lambda$ (pentru ca x e repartizata Poisson).

Acum inlocuim ce am calculat mai sus in formula pentru MIRC:

$$\begin{aligned}
MIRC_{pois} &= \frac{1}{-n \cdot E\left[\frac{\partial^2}{\partial \lambda^2} \ln(f_\lambda(x))\right]} = \\
&= \frac{1}{-n \cdot \frac{-1}{\lambda}} \\
&= \frac{\lambda}{n}
\end{aligned} \tag{9}$$

In R am luat un exemplu ca sa ne putem verifica. Am luat $X \sim \text{Poisson}(5)$. Am luat $n=100$ si $\lambda = 5$. In acest caz, $MIRC = \frac{\lambda}{n} = \frac{5}{100} = 0.05$, aproximativ cat ne-a dat si in urma

ularii functiei frcpois in R.

MIRC

0.0505050505050505

```
frcpois <- function(n,lambda,x)
{
  der2 <- function(lambda,x)
  {
    (lambda^((x-1)-1)*(x-1)*exp(-lambda) - lambda^((x-1)*x*exp(-lambda)-(lambda^(x-1)*
    x*exp(-lambda)-lambda*x*exp(-lambda)))/factorial(x)/(lambda*x*exp(-lambda)/factorial(x))-
    (lambda^((x-1)*x*exp(-lambda)-lambda*x*exp(-lambda))/factorial(x)*
    ((lambda^(x-1)*x*exp(-lambda)-lambda*x*exp(-lambda))/factorial(x))/(lambda*x*exp(-lambda)/factorial(x))^2
    }
    #derivata de ordin doi introdusa manual
MIRC <- 1/(-n*mean(eval(der2(lambda,x))))
return(MIRC)
}

p <- rpois(n,5)
MIRC <- frcpois(n,5,p)
```

- Functia frcrexp:

Functia de densitate a repartitiei Exponentiale este:

$$f(x, \lambda) = \begin{cases} \lambda \cdot e^{-\lambda x} & , x \geq 0 \\ 0 & , x < 0 \end{cases} \quad (10)$$

Aplicam logaritm natural:

$$\ln(f_{\lambda}(x)) = \ln(\lambda \cdot e^{-\lambda x}) = \ln(\lambda) - \lambda x \quad (11)$$

Derivam de doua ori in functie de λ :

$$\begin{aligned}
\frac{\partial}{\partial \lambda} (f_{\lambda}(x)) &= \\
&= \frac{\partial}{\partial \lambda} (\ln(\lambda) - \lambda x) \\
&= \frac{1}{\lambda} - x
\end{aligned} \tag{12}$$

$$\begin{aligned}
\frac{\partial^2}{\partial \lambda^2} \left(\frac{1}{\lambda} - x \right) &= \\
&= -\frac{1}{\lambda^2} \\
E \left[\frac{\partial^2}{\partial \lambda^2} (f_{\lambda}(x)) \right] &= E \left[-\frac{1}{\lambda^2} \right] = -\frac{1}{\lambda^2}
\end{aligned} \tag{13}$$

Inlocuim ce am calculat mai sus in formula pentru MIRC:

$$\begin{aligned}
MIRC_{exp} &= \frac{1}{-n \cdot E \left[\frac{\partial^2}{\partial \lambda^2} (f_{\lambda}(x)) \right]} = \\
&= \frac{1}{-n \cdot -\frac{1}{\lambda^2}} \\
&= \frac{\lambda^2}{n}
\end{aligned} \tag{14}$$

In R am luat un exemplu ca sa ne putem verifica. Am luat $X \sim \text{Exp}(3)$.
Am luat $n=100$ si $\lambda = 3$.
In acest caz, $MIRC = \frac{\lambda^2}{n} = \frac{9}{100} = 0.09$, aproximativ cat ne-a dat si in urma rularii functiei `frcexp` in R.

```
MIRC                                0.09000000000000001
```

```

frcexp <- function(n,X,lambd)
{
  deriv2 <- function(lambd,X) {
    -((exp(-lambd*X)*X+((exp(-lambd*X)*X)-lambd*(exp(-lambd*X)*X^2)))/
      (lambd*exp(-lambd*X)+(exp(-lambd*X)-lambd*(exp(-lambd*X)*X))*(exp(-lambd*X)-
        lambd*(exp(-lambd*X)*X))/(lambd*exp(-lambd*X))^2)
    }
  #derivata de ordin 2 introdusa manual, din nou
  MIRC <- 1/(-n*mean(eval(deriv2(lambd,X))))
  return(MIRC)
}

e <- rexp(n)
MIRC <- frcexp(n,e,3)

```

5 Exercițiul 5

5. a) Construiți o funcție care calculează media unei variabile aleatoare, primind ca parametri de intrare tipul variabilei aleatoare(discretă sau continuă) și densitatea/funcția de masă, după caz. Comparați cu rezultatul teoretic.
- b) Construiți o funcție care calculează dispersia unei variabile aleatoare, folosindu-vă de funcția care calculează media. Comparați cu rezultatul teoretic.
- c) Construiți o funcție care calculează funcția generatoare de momente pentru variabila aleatoare X pentru un interval dat(discretizat de un vector t, care este parametru de intrare pentru funcție).
- d) Aproximați media și dispersia variabilei aleatoare X folosind funcția generatoare de momente de la c). Comparați cu rezultatele obținute la a) și b).

- Cazul discret:

$$X \sim \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix} \quad (15)$$

- a) Media unei variabile aleatoare discrete X e definita astfel:

$$E[X] = x_1p_1 + \dots + x_np_n = \sum_{i=1}^n x_ip_i \quad (16)$$

Varianta:

$$Var(X) = E[X^2] - E[X]^2 \quad (17)$$

b) Dispersia(deviatia standard):

$$Dispersia = \sqrt{Var(X)} \quad (18)$$

c) Functia generatoare de momente pentru cazul discret are urmatoarea formula:

$$FGM(t) = \sum_{i=1}^n p_i e^{tx_i}, \quad (19)$$

unde t este vectorul care discretizeaza intervalul.

• Cazul continuu:

a) Media unei variabile aleatoare continue X este:

$$E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx, \quad (20)$$

unde f(x) este densitatea de probabilitate lui X.

Varianta:

$$Var(X) = E[X^2] - E[X]^2 = \int_{-\infty}^{\infty} x^2 \cdot f(x) dx - E[X]^2 \quad (21)$$

b) Dispersia(deviatia standard):

$$Dispersia = \sqrt{Var(X)} \quad (22)$$

c) Functia generatoare de momente pentru cazul continuu are urmatoarea formula:

$$FGM(t) = \int_{-\infty}^{\infty} e^{tx} \cdot f(x) dx, \quad (23)$$

unde f(x) este densitatea de probabilitate a lui X si t este vectorul care discretizeaza intervalul.

In R am luat exemplul pentru $X \sim Exp(\lambda)$ cu $\lambda = 5$. N-am reusit sa calculez in R functia generatoare de momente. Aceasta era functia initiala:

```
FGM_continuu <- function(t)
{ phi2 <- c()
  for(i in 1:length(t))
  { f3 <- function(x) {return(exp(t[i]*x)*lambda*exp(-lambda*x))} #functia din interiorul integralei pt FGM
    phi2[i] <- integrate(f3,lower=0,upper=Inf)}
  return(phi2)
}
phi2=FGM_continuu(t)
```

Am notat cu phi2=functia generatoare de momente pt cazul continuu, FGMcontinuu=functia in care vreau sa calculez phi2, f3=functia in care aflu integrandul pentru fiecare t[i].

Eroarea care imi apare este aceasta:

```
Error in integrate(f3, lower = 0, upper = Inf) :
  non-finite function value
In addition: There were 50 or more warnings (use warnings() to see the first 50)
```

Asa ca am calculat de mana functia generatoare de momente:

$$\begin{aligned}
 MGF(t) &= \int_0^{\infty} e^{tx} \cdot \lambda \cdot e^{-\lambda x} dx \\
 &= \lambda \int_0^{\infty} e^{x(t-\lambda)} dx \\
 S.V. : x(t-\lambda) &= y, x=0 \longrightarrow y=0, x=\infty \longrightarrow y=-\infty \\
 &= \lambda \cdot \int_0^{-\infty} e^y \cdot \frac{1}{t-\lambda} dy \\
 &= \dots = \frac{\lambda}{\lambda-t}, \lambda > t
 \end{aligned} \tag{24}$$

d) Legatura dintre functia generatoare de momente si medie si dispersie:

$$\begin{aligned}
 E[X] &= MGF'(0) \\
 E[X^2] &= MGF''(0) \\
 Var(X) &= MGF''(0) - (MGF'(0))^2 \\
 Dispersia &= \sqrt{MGF''(0) - (MGF'(0))^2}
 \end{aligned} \tag{25}$$

Pentru cazul discret, functia generatoare de momente ne da:

6 Exercițiul 6

6. a) Pentru repartițiile **logistică** și respectiv **Cauchy**(vezi problema 1) construiți *funcția de verosimilitate* pentru parametrul μ considerând că parametrii β și respectiv σ sunt cunoscuți(alegeți valori potrivite pentru aceștia).

b) Reprezentați grafic funcțiile de verosimilitate pentru cele două cazuri și folosind funcția **optimise** determinați o estimatie pentru μ în baza unui eșantion de dimensiune 1000 pe care l-ați construit în prealabil. Explicați modul în care ați generat valorile din eșantion. Comentați și interpretați rezultatele.

a) Stim de la 1.a) inversa funcției de repartitie pentru repartitia logistica:

$$F^{-1}(u) = -\beta \cdot \ln(1 - u) + \beta \cdot \ln(u) + \mu \quad (26)$$

Funcția de verosimilitate are formula:

$$L_{logis}(\mu/(x_1, \dots, x_n)) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\beta} \cdot \frac{e^{-\frac{(x - \mu)}{\beta}}}{\left(1 + e^{-\frac{(x - \mu)}{\beta}}\right)^2}, \quad (27)$$

unde: f_{μ} este densitatea data la exercitiul 1, iar β este fixat.

Rezolvarea in R:

```
#generam valori din repartitia logistica cu functia predefinita rlogis
n <- 100
x <- rlogis(n,0,1) #x este un vector de 100 de elemente
                    #ce va contine valori din repartitia logistica

L <- 1; #initializam produsul cu 1
beta <- 1; #alegem o valoare potrivita pentru beta fixat

#mai jos vom calcula functia de verosimilitate
#miu este parametrul nostru(theta din formulele din curs)

verosim_logi <- function(miu)
{
  for(i in 1:n)
  {
    L <- L*(1/beta)*exp(-(x[i]-miu)/beta)/(1+exp(-(x[i]-miu)/beta))^2;
  }
  return(L)
}
```

Inversa functiei de repartitie pentru repartitia Cauchy este:

$$F^{-1}(u) = \sigma \cdot tg\left(\pi\left(\frac{2u-1}{2}\right)\right) + \mu \quad (28)$$

Functia de verosimilitate are formula:

$$L_{Cauchy}(\mu/(x_1, \dots, x_n)) = \prod_{i=1}^n f_{\mu}(x_i) = \prod_{i=1}^n \frac{1}{\pi\sigma} \cdot \frac{1}{1 + \left(\frac{x_i - \mu}{\sigma}\right)^2}, \quad (29)$$

unde: f_{μ} este densitatea data la exercitiul 1, iar σ este fixat.

Rezolvarea in R:


```
#procedam exact ca mai sus de data aceasta pentru repartitia Cauchy
```

```
y<- rcauchy(n,0,1)
sigma <- 1;
L <- 1
verosim_cauchy <- function(miu){
  for(i in 1:n){
    L <- L*(1/(pi*sigma))*1/(1+((y[i]-miu)/sigma)^2)
  }
  return(L)
}
```

b)

- Codul in R pentru graficul repartitiei logistice:

```
#trasam graficul functiei de verosimilitate pentru repartitia Logistica
plot(verosim_logi,xlab='miu',ylab='L(miu)', col="purple")
title("Graficul functiei de verosimilitate pentru repartitia Logistica")
```



Cautam valoarea optima pentru μ :


```
miu_logis <- optimise(verosim_logi,c(0,1),maximum=TRUE)
miu_optim <- miu_logis[[1]]
```

Valoarea este:

miu_optim	0.250254283271973
-----------	-------------------

- Codul in R pentru graficul repartitiei Cauchy:

```
plot(verosim_cauchy,xlab='miu',ylab='L(miu)', col="red")  
title("Graficul functiei de verosimilitate pentru repartitia Cauchy")
```



Cautam valoarea optima pentru μ :

```
miu_cauchy <- optimise(verosim_cauchy,c(0,1),maximum=TRUE)  
miu_optim2 <- miu_cauchy[[1]]
```

Valoarea este:

miu_optim2	0.381527882906245
------------	-------------------

Interpretarea celor 2 grafice:

Dupa ce am generat mai multe grafice, am observat ca atat functia de verosimilitate pentru repartitia logistica, cat si cea pentru repartitia Cauchy

se apropie de 0 cu cat marim esantionul.

Referitor la constructia parametrului nostru, (μ) , constatam ca aceasta este posibila pe un interval restrans(bucula din imagine) pentru ca, dupa aceea, μ are valoarea constant egala cu 0.